Entwurfsbeschreibung-DeepWalk4J

Analyse der Eingabedaten

https://snap.stanford.edu/data/egonets-Twitter.html
http://i.stanford.edu/~julian/pdfs/nips2012.pdf

nodeId.edges : The edges in the ego network for the node 'nodeId'. Edges are undirected for facebook, and directed (a follows b) for twitter and gplus. The 'ego' node does not appear, but it is assumed that they follow every node id that appears in this file.
nodeId.circles : The set of circles for the ego node. Each line contains one circle, consisting of a series of node ids. The first entry in each line is the name of the circle.
nodeId.feat : The features for each of the nodes that appears in the edge file.
nodeId.egofeat : The features for the ego user.
nodeId.featnames : The names of each of the feature dimensions. Features are '1' if the user has this property in their profile, and '0' otherwise. This file has been anonymized for facebook users, since the names of the features would reveal private data.

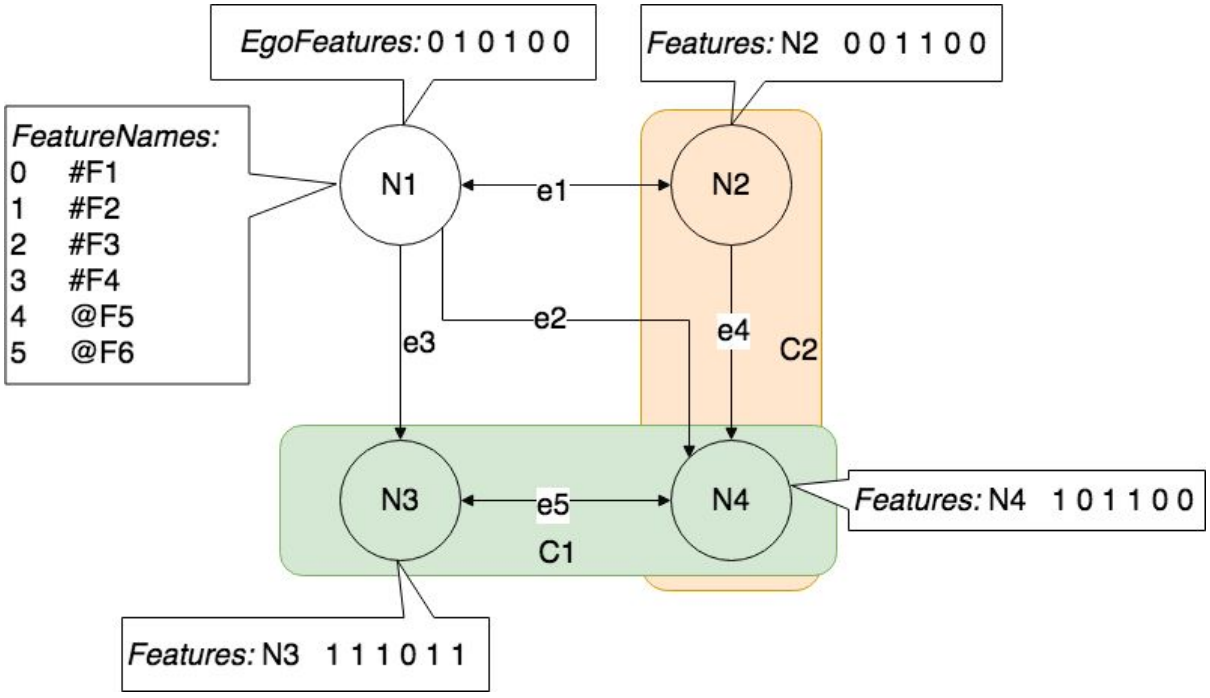

Preprocessing

Ziel: Eingabedaten in ein einfach verarbeitbares Format konvertieren

Für das Preprocessing der Knoten und Kanten werden aus der Datei ‘twitter_combined.txt’ alle vorkommenden Knoten in eine Datei ‘combined_vertices.txt’ ausgegeben. Die Feature-Vektoren werden aus den ‘NodeID.egofeat’ und ‘NodeID.feat’ ausgelesen und für jeden Knoten jeweils einer Datei ausgegeben. Dabei werden die 0/1 Werte durch die

Richtigen Feature Label ausgetauscht. Dadurch können die Featuredaten sehr einfach durch die Paragraph Vektoren gelesen und verwendet werden.

Graph initialisierung

- vertices aus datei combined_veritces.txt
- edges aus datei combined_edges.txt
- label mapping zur verwendung von internen inkrementellen ids
- zusätzliche kanten für degree=0 auf sich selber

DeepLearning4J

Das DeepLearning4J[1] framework dient zur Entwicklung dieser Aufgaben. Es realisiert eine Implementierung des DeepWalk und ParagraphVector Modells.

DeepWalk:

Ziel: Vorbereitete Knoten und Kanten laden, Graph erstellen, DeepWalk mit eigenen Windowsize und Walklength. Diese muss auf der internen Deeplearning4J-Repräsentation eines Graphen initialisiert werden, welcher aus den Dateien ‘combined_vertices.txt’ und ’combined_edges.txt’ erstellt wird. Der DeepWalk-Instanz werden bei Erstellung Werte für die Anzahl der Layer oder Größe des Windows übergeben. Diese Werte können bei Aufruf des Tools in der Kommandozeile konfiguriert werden. Dazu lässt sich noch die Länge der Walks konfigurieren auf denen die DeepWalk Embeddings generiert werden

ParagraphVectors:

Ziel: Vorbereitete Features Laden, Vektoren mit eigenen Windowsize erstellen

Die Feature Daten liegen für jeden Knoten als Datei vor, welche als Namen die ID des Knoten und als Inhalt eine durch Whitespaces getrennte Liste an Features besitzt.

Persistierung:

Ziel: Generierte DeepWalk und ParagraphVector Embeddings speichern und laden

Zur Persistierung werden die vorhanden Serialisierungen DeepLearning4Js genutzt um die geladenen DeepWalk und ParagraphVector Embeddings im Dateisystem abzuspeichern. Dazu gibt es auch passende Methoden, welche diese wieder laden.

[1] https://deeplearning4j.org/

Anhang

Der Quellcode ist in folgendem Link zu finden.

```
https://github.com/Termilion/Deep-Walk-4J
```

Referenzen

[1] Q. V. Le and T. Mikolov. Distributed Representations of Sentences and Documents. 32, 2014. https://cs.stanford.edu/~quocle/paragraph_vector.pdf

[2] B. Perozzi and S. Skiena. DeepWalk : Online Learning of Social Representations Categories and Subject Descriptors. http://www.perozzi.net/publications/14_kdd_deepwalk.pdf